

RELATÓRIO TÉCNICO DE ANÁLISE DE DADOS E ENGENHARIA

Desafio Técnico — Indicium / LH Nauticals

Analista: Barbara Sales Brasil

1. Visão Geral e Justificativa da Dimensão de Calendário

A implementação de uma Dimensão de Calendário (*Calendar Table*) é indispensável na modelagem de dados para eliminar o viés de seleção estrutural. Em bases transacionais, dias sem faturamento não possuem registros. Agrupar diretamente as transações ignoraria esses vazios, inflando falsamente a média de vendas de determinados dias da semana.

- **Blindagem Analítica:** Cruzar as vendas com uma grade contínua de datas (**LEFT JOIN** com **COALESCE** para zero) garante denominador real e precisão nos indicadores. Adicionalmente, atua como barreira contra anomalias e registros corrompidos com datas futuras originados no ERP.

2. Previsão de Demanda (Baseline e Limitações)

Utilizando o produto "**Bússola de Bordo 702**" e o modelo baseline de média móvel simples de 3 meses com defasagem temporal estrita (**shift(1)** para evitar *data leakage*):

- **a. O baseline é adequado?** Atua de forma satisfatória apenas como ponto de partida reativo. Sua adequação real depende de um comportamento de demanda estável, falhando em cenários de alta volatilidade ou crescimento acelerado.
- **b. Limitação principal:** O atraso temporal (*lag*). O modelo suaviza variações bruscas e reage tardiamente a mudanças repentinas de mercado, expondo a operação a riscos de ruptura de estoque (*stockout*) ou excesso de mercadoria encalhada.

3. Sistema de Recomendação por Similaridade de Cosseno

- **Construção da Matriz:** Foi estruturada uma matriz esparsa de interação Usuário $\times$ Produto em formato binário de presença e ausência (\$1\$ ou \$0\$), mapeando se o cliente (`customer_id`) adquiriu ou não o item, isolando o viés puramente quantitativo.
- **Significado da Similaridade de Cosseno:** Mede o cosseno do ângulo entre os vetores de dois produtos no espaço multidimensional dos clientes, indicando o grau de sobreposição do público comprador entre os itens.
- **Limitação do Método:** A esparsidade de dados (*sparsity*) e o viés de popularidade, que dificultam recomendações assertivas na cauda longa do catálogo.
- **Nota Crítica de Data Quality:** A exploração analítica e o cruzamento evidenciaram ruídos herdados do sistema de origem — como o artefato de *placeholder* anômalo ("asdf") que obteve correlação matemática nos testes. Isso reforça a criticidade de camadas de sanitização (*Silver/Gold*).

4. Regras de Ouro de Data Quality (Blindagem do Pipeline)

Para garantir a confiabilidade contínua da camada analítica e blindar a tomada de decisão executiva contra falhas operacionais do ERP, o pipeline foi estruturado sob os seguintes pilares de governança:

1. **Regra de Integridade Referencial (*Referential Integrity*):** Validação estrita de chaves estrangeiras (*Foreign Keys*) para impedir registros órfãos ou vinculados a entidades inexistentes.
2. **Regra de Consistência Temporal (*Temporal Consistency*):** Auditoria contínua de carimbos de data/hora (`created_at`) para assegurar a ordem cronológica transacional e mitigar falhas de sincronização.
3. **Regra de Unicidade (*Uniqueness*):** Monitoramento periódico de chaves primárias (`id`) para evitar duplicações capazes de inflar métricas financeiras.
4. **Regra de Completude de Atributos (*Attribute Completeness*):** Alertas automáticos em campos críticos (como valores e moedas) para interceptar anomalias antes da consolidação executiva.

Diagramas de análise

